

Università San Raffaele - Roma

***Ingegneria Informatica e dell'Intelligenza Artificiale
Applicata***

***Corso "Apprendimento Automatico e Apprendimento
Profondo"***

Relazione sull'elaborato richiesto per l'esame del corso

Studente:
Michele De Rose
Matr. 0322500130

Introduzione

L'obiettivo del progetto è lo sviluppo di un esperimento di classificazione utilizzando algoritmi di machine learning in linguaggio Python e l'implementazione di un approccio di Explainable AI.

Dataset utilizzato

Per l'addestramento e la valutazione dei modelli è stato scelto il dataset "Car Evaluation" (<https://archive.ics.uci.edu/dataset/19/car+evaluation>), dal repository UCI Machine Learning.

Il dataset si compone di 1728 campioni e descrive le caratteristiche di diversi veicoli attraverso 6 feature puramente categoriche e ordinali:

- **buying**: Prezzo di acquisto del veicolo (low, med, high, vhigh).
- **maint**: Costo di manutenzione (low, med, high, vhigh).
- **doors**: Numero di porte (2, 3, 4, 5more).
- **persons**: Capienza passeggeri (2, 4, more).
- **lug_boot**: Dimensioni del bagagliaio (small, med, big).
- **safety**: Livello di sicurezza stimato (low, med, high).

La variabile target, definita per la stima dell'accettabilità complessiva del veicolo, risulta articolata in quattro distinte categorie:

- **unacc** (inaccettabile),
- **acc** (accettabile),
- **good** (buona) e
- **vgood** (ottima).

Da una prima esplorazione dei dati emerge il fatto che il dataset sia fortemente sbilanciato verso la classe *unacc*:

Classe	Significato	Campioni	%
unacc	Inaccettabile	1210	70.0%
acc	Accettabile	384	22.2%
good	Buona	69	4.0%
vgood	Ottima	65	3.8%

Questo sbilanciamento della distribuzione dei dati è un fattore critico, che è stato preso in forte considerazione durante la successiva fase di partizionamento dei dati e per la scelta delle metriche di valutazione più opportune.

1. Pre-processing dei Dati e Scelte Progettuali

Per poter alimentare correttamente i modelli di Machine Learning, le feature puramente testuali e la variabile target del dataset hanno richiesto opportune operazioni di trasformazione e codifica.

Gestione delle Variabili Categoricali

Al fine di convertire le feature in formato numerico, si è scelto di escludere l'utilizzo della tecnica del One-Hot Encoding, la cui adozione avrebbe generato un elevato numero di variabili dummy incrementando drasticamente la dimensionalità del dataset.

Poiché i dati presentano una naturale gerarchia ordinabile (come nel caso del prezzo, da low a vhigh), si è optato per l'**Ordinal Encoding**, preservando l'ordinamento semantico (es.: low=0, med=1, high=2, vhigh=3).

Encoding della Variabile Target e Standardizzazione

La variabile target è stata codificata tramite una mappatura manuale (`{'unacc': 0, 'acc': 1, 'good': 2, 'vgood': 3}`) per preservare l'ordinamento semantico delle classi (da *inaccettabile* a *ottima*), garantendo una rappresentazione corretta nei grafici come la matrice di confusione.

Per quanto concerne la standardizzazione (mediante *StandardScaler*), essa è stata applicata in una fase successiva al partizionamento del dataset. In particolare, per evitare il fenomeno del **Data Leakage**, lo scaler è stato adattato (fit) esclusivamente sui dati di addestramento e successivamente applicato per trasformare i dati di test.

Questa precauzione garantisce una valutazione robusta e non viziata dei modelli.

Partizionamento del Dataset (Data Splitting)

In conformità a quanto appreso durante le lezioni, il dataset è stato partizionato dedicando

- il 70% dei campioni al Training Set,
- il 15% al Validation Set e
- il 15% al Test Set.

L'implementazione pratica con *train_test_split* ha richiesto due fasi per rispettare tali proporzioni:

1. Nella prima fase è stato isolato un 15% assoluto dal totale, destinandolo al Test Set.
2. Nella seconda fase, per ricavare il Validation Set dal blocco residuo dell'85%, è stata applicata una proporzione calcolata ad hoc ($15 / 85 \approx 17.65\%$), prelevando dunque il 17,65% della frazione rimanente. Il resto (l'82,35% dell'85%) ha composto correttamente il restante 70% per il Training Set.

2. Task 1: Analisi delle Feature con PCA

Introduzione Teorica alla PCA

L'**Analisi delle Componenti Principali** (PCA) è una tecnica di riduzione della dimensionalità utilizzata per estrarre le feature più rilevanti.

Trasformando le variabili originali in un nuovo insieme di variabili linearmente indipendenti, permette di comprimere l'informazione massimizzando la varianza spiegata.

Varianza Spiegata

Applicando la PCA ai dati standardizzati, è stata calcolata la varianza cumulativa spiegata dalle diverse componenti per comprendere quante componenti siano effettivamente necessarie. L'analisi della varianza evidenzia come il dataset presenti un'informazione fortemente distribuita tra le 6 feature originali.




Figura 1: Grafico della varianza cumulativa spiegata all'aumentare del numero di componenti.

L'analisi della varianza evidenzia come il dataset presenti un'informazione fortemente distribuita tra le 6 feature originali: le prime due componenti non sono sufficienti a spiegare la totalità della varianza. Questo dimostra che il dataset, seppur composto da poche feature, racchiude una complessità informativa tale da non poter essere drasticamente compresso senza una sensibile perdita di dettaglio.

Proiezione 2D e Separabilità delle Classi

La trasformazione bidimensionale (PC1 e PC2) si rivela uno strumento esplorativo prezioso per visualizzare la distribuzione su un piano cartesiano. La PCA visiva in 2D è stata applicata esclusivamente al Training Set per evitare *data leakage* visivo.




Figura 2: Proiezione bidimensionale del dataset sulle prime due componenti principali.

Come si evince dallo scatter plot, i dati appaiono fortemente sovrapposti e intersecati, senza alcuna separabilità lineare evidente. Questa non-linearità giustifica la necessità di adottare modelli complessi nel Task 2.

3. Task 2 & 3: Implementazione e Valutazione degli Algoritmi

Scelta dei Modelli di Classificazione

Sono stati implementati tre algoritmi:

- **Support Vector Machine (SVM)**: Utilizzo del Kernel RBF, capace di mappare i dati in uno spazio a dimensione superiore e gestire distribuzioni non-lineari.
- **Random Forest**: Metodo ensemble eccellente per mitigare l'overfitting e gestire variabili categoriche/ordinali.
- **Gaussian Naive Bayes (NB)**: Baseline prestazionale basata sull'indipendenza condizionata tra le feature.

Metriche di Valutazione

Per confrontare l'efficacia dei modelli, sono state calcolate le principali metriche di classificazione. A causa del forte sbilanciamento delle classi, si è fatto ricorso alla media macro per Precision, Recall e F1-Score, oltre al calcolo della metrica ROC AUC tramite strategia One-vs-Rest (OvR).

	Accuracy	Precision	Recall	F1-Score	ROC AUC
SVM	0.976923	0.944452	0.917942	0.922614	0.999100
Random Forest	0.976923	0.927506	0.915006	0.916773	0.999204
Naive Bayes	0.692308	0.406776	0.512884	0.362945	0.888925

Confronto prestazionale dei tre classificatori sul Test Set.


Dall'analisi della tabella di confronto prestazionale dei tre modelli si evince chiaramente che **Random Forest** e **SVM** dimostrano performance eccellenti e superiori al Naive Bayes nel decifrare pattern non lineari.


4. Task 4: Analisi Visiva delle Performance

Matrici di Confusione

Le matrici di confusione agevolano un'analisi disaggregata della distribuzione dei veri positivi e degli errori.

Grazie all'adozione del custom encoding della variabile target, le classi nelle matrici seguono l'ordine semantico corretto ("unacc", "acc", "good", "vgood"), facilitando la lettura degli errori che si concentrano, fisiologicamente, solo ai confini decisionali tra classi adiacenti.










Figura 3 (a, b, c): Matrici di Confusione relative ai tre modelli (SVM, Random Forest, Naive Bayes).

Curve ROC e AUC Multi-classe

Le Curve ROC confermano la spiccata capacità discriminativa della Random Forest e della SVM, assicurando sulla robustezza dei modelli nel differenziare le classi minoritarie nonostante lo sbilanciamento dei dati nel dataset di origine.








Figura 4 (a, b, c): Curve ROC Multi-classe e relativi valori di AUC per ciascuno dei modelli analizzati.

L'andamento delle curve e i valori numerici dell'Area Sottesa (AUC) ratificano inconfutabilmente la spiccata capacità discriminativa della Random Forest e della SVM, le cui curve descrivono andamenti tendenti in modo deciso verso il limite superiore sinistro del grafico.

I valori di AUC **prossimi all'unità** certificano una notevole robustezza dei modelli nel differenziare con successo le classi minoritarie (*good* e *vgood*), fornendo solide rassicurazioni sulla validità della gestione dello sbilanciamento originario.

5. Task 5: Explainable AI con SHAP

L'Importanza della Spiegabilità

Al fine di interpretare le dinamiche decisionali della Random Forest (il modello più performante), si è optato per la libreria SHAP e il modulo TreeExplainer.



Figura 5: Summary Plot (Feature Importance) per la classe “unacc”.




Figura 6: Summary Plot globale multi-classe (Bar chart)

Come si evince graficamente dai Summary Plot, la metodologia SHAP consente non solo di stilare una classifica globale oggettiva delle feature più influenti sulle decisioni (Feature Importance), ma anche di comprendere la direzione predittiva del loro impatto per determinati range di valori.

Ad esempio, è possibile osservare visivamente come le feature “**safety**” e “**persons**” (rispettivamente “livello di sicurezza” e “capienza”) giochino il ruolo di gran lunga più determinante nel far convergere la classificazione verso la categoria “inaccettabile”, rispecchiando e confermando in toto le aspettative logiche umane sul problema analizzato.

Conclusioni

L'elaborato dimostra l'efficacia delle principali tecniche di Machine Learning su feature categorico-ordinali, con la **Random Forest** che si conferma il modello più idoneo per gestire le non-linearità.

L'integrazione conclusiva del processo di Explainable AI ha infine certificato la totale trasparenza decisionale e l'affidabilità dell'algoritmo.

Michele De Rose
Matr. 0322500130

Appendice: Configurazione dell'Ambiente Virtuale

A differenza di quanto esplorato durante le lezioni del corso, in cui è stato presentato l'utilizzo del gestore di pacchetti Conda (parte della suite Anaconda), per la stesura e l'implementazione di questo elaborato si è scelto di adottare **venv**, lo strumento nativo integrato nella standard library di Python.

Istruzioni per l'avvio dell'ambiente

Per riprodurre ed eseguire correttamente il codice sorgente associato a questo progetto, è sufficiente aprire un terminale all'interno della cartella radice del progetto ed eseguire il seguente comando di attivazione:

```
.\venv\Scripts\activate
```

Una volta attivato (la console mostrerà il prefisso (venv) accanto al percorso), sarà possibile lanciare *Jupyter Notebook* in un ambiente isolato e coerente, pronto all'uso senza incorrere in conflitti di versione.

Successivamente all'attivazione dell'ambiente, per replicare in modo esatto l'ecosistema software del progetto, è indispensabile procedere all'installazione dei pacchetti necessari sfruttando il gestore pip. Da riga di comando sarà sufficiente eseguire:

```
pip install -r requirements.txt
```

Sommario

Introduzione.....	1
Dataset utilizzato.....	1
1. Pre-processing dei Dati e Scelte Progettuali.....	3
Gestione delle Variabili Categoricali.....	3
Encoding della Variabile Target e Standardizzazione.....	3
Partizionamento del Dataset (Data Splitting).....	4
2. Task 1: Analisi delle Feature con PCA.....	5
Introduzione Teorica alla PCA.....	5
Varianza Spiegata.....	5
Proiezione 2D e Separabilità delle Classi.....	6
3. Task 2 & 3: Implementazione e Valutazione degli Algoritmi.....	8
Scelta dei Modelli di Classificazione.....	8
Metriche di Valutazione.....	8
4. Task 4: Analisi Visiva delle Performance.....	10
Matrici di Confusione.....	10
Curve ROC e AUC Multi-classe.....	12
5. Task 5: Explainable AI con SHAP.....	16
L'Importanza della Spiegabilità.....	16
Conclusioni.....	18
Appendice: Configurazione dell'Ambiente Virtuale.....	19
Istruzioni per l'avvio dell'ambiente.....	19